

## ----- OPTIMIZATION AND GAME THEORY -----

### Set Convesso

Il set  $C \subseteq \mathbb{R}^n$  è **convesso** se  $\forall x, y \in C$  and  $\forall \alpha \in [0, 1] \rightarrow \alpha x + (1 - \alpha)y \in C$

### Set Affine

Il set  $C \subseteq \mathbb{R}^n$  è **affine** se  $\forall x, y \in C$  and  $\forall \alpha \in \mathbb{R} \rightarrow \alpha x + (1 - \alpha)y \in C$

### Combinazione Convessa

$$y = \sum_{i=1}^k \alpha_i x_i \quad \text{con: } 1) \alpha_1 \dots \alpha_k \in [0, 1], \quad 2) \sum_{i=1}^k \alpha_i = 1$$

### Lemma 1

**SE**  $C$  è convesso  $\rightarrow \forall x_1 \dots x_k \in C$  and  $\alpha_1 \dots \alpha_k \in [0, 1] : \sum_{i=1}^k \alpha_i = 1$ ,

$$\sum_{i=1}^k \alpha_i x_i \in C$$

### Proposizione

**SE**  $\{C_i\}_{i \in I}$  rappresenta ogni possibile famiglia di set convessi  $\rightarrow \bigcap_{i \in I} C_i$  è convesso

Informalmente: l'**intersezione** di set convessi è anch'esso convesso

### Convex Hull

$\text{conv}(C)$  di un set  $C$  è il più piccolo set convesso che contiene  $C$

### Proposizione

$\text{conv}(C) = \{\text{tutte le combinazioni convesse dei punti in } C\}$

### Nota

$\text{conv}(C) = C$  per  $C$  convesso

### Definizione di Poliedro

Un poliedro  $P$  è l'intersezione di un numero finito di semipiani in  $\mathbb{R}^n$

### Somma Di Set Convessi

Siano  $C_1$  e  $C_2$  set convessi  $\rightarrow C_1 + C_2 := \{x + y : x \in C_1, y \in C_2\}$  è convessa (Vale anche per la differenza)

### Prodotto Di Set Convessi

Sia  $C$  un set convesso  $\rightarrow \alpha \cdot C := \{\alpha \cdot x : x \in C\}$  è convesso

### Closure

$C$  convesso  $\rightarrow \text{cl}(C)$  è convesso

### Interior

$C$  convesso  $\rightarrow \text{int}(C) \neq \emptyset$  è convesso

### Affine Set

Sia  $C \subseteq \mathbb{R}^n \rightarrow \text{aff}(C)$  è il più piccolo set affine che contiene  $C$

### Relative Interior

Sia  $C \subseteq \mathbb{R}^n$  convesso  $\rightarrow \text{ri}(C) := \{x \in C : \exists \epsilon > 0: \text{aff}(C) \cap B(x, \epsilon) \subseteq C\}$

### Teorema

Sia  $C \subseteq \mathbb{R}^n$  set convesso non vuoto  $\rightarrow \text{ri}(C)$  è convesso non vuoto

### Teorema

Siano  $A, B \subseteq \mathbb{R}^n$  due set convessi non vuoti  $\rightarrow A$  e  $B$  sono linearmente separabili **SSE**  
 $\text{ri}(A) \cap \text{ri}(B) = \emptyset$

### Funzioni Affine

Sia  $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$  affine, ovvero  $f(x) = Ax + b$  con  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^m$ .

**SE**  $C \subseteq \mathbb{R}^n$  è convesso  $\rightarrow f(C) = \{f(x) : x \in C\}$  è convesso

**SE**  $C \subseteq \mathbb{R}^m$  è convesso  $\rightarrow f^{-1}(C) = \{x \in \mathbb{R}^n : f(x) \in C\}$  è convesso

### Definizione Di Cono

Un set  $C \subseteq \mathbb{R}^n$  è un cono **SE**  $\forall x \in C, \forall \lambda > 0 \rightarrow \lambda x \in C$

### Cono Di Recessione

Dato un poliedro  $P = \{x: Ax \leq b\}$  il cono di recessione di  $P$  è

$$\text{rec}(P) := \{d: x + \alpha \cdot d \in P, \quad \forall x \in P, \quad \alpha > 0\}.$$

### Cono Tangente •••

Dato  $x' \in \text{cl}(C) \subseteq \mathbb{R}^n$  il cono tangente a  $x'$  è:

$$T_C(x') := \{d \in \mathbb{R}^n: \exists \{z_k\} \subset C, \exists \{t_k\} > 0, z_k \rightarrow x', t_k \rightarrow 0, \lim_{k \rightarrow \infty} \frac{z_k - x'}{t_k} = d\}$$

### Funzione Convessa

Sia  $C \subseteq \mathbb{R}^n$  set convesso. Una funzione  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  è convessa in  $C$  se

$$f(\alpha y + (1 - \alpha)x) \leq \alpha f(y) + (1 - \alpha)f(x) \quad \forall x, y \in C, \quad \forall \alpha \in [0, 1]$$

### Teorema

$f: \mathbb{R}^n \rightarrow \mathbb{R}$  è convessa in  $\mathbb{R}^n$  **SSE**  $\text{epi } f_C := \{(x, y) \in C \times \mathbb{R}: y \geq f(x)\}$  è convesso

### Funzione Concava

Sia  $C \subseteq \mathbb{R}^n$  set convesso. Una funzione  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  è concava in  $C$  se  $-f$  è convessa in  $C$

$$f(\alpha y + (1 - \alpha)x) \geq \alpha f(y) + (1 - \alpha)f(x) \quad \forall x, y \in C, \quad \forall \alpha \in [0, 1]$$

### Teorema

$f: \mathbb{R}^n \rightarrow \mathbb{R}$  è convessa in  $C \subseteq \mathbb{R}^n$  set convesso  $\rightarrow f$  continua nel  $\text{ri}(C)$

### Strictly Convex

Dato  $C \subseteq \mathbb{R}^n$  set convesso,  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  è **strictly** convex in  $C$  se

$$f(\alpha y + (1 - \alpha)x) < \alpha f(y) + (1 - \alpha)f(x), \quad \forall x, y \in C, \quad x \neq y, \quad \forall \alpha \in (0, 1)$$

### Strongly Convex

Dato  $C \subseteq \mathbb{R}^n$  set convesso,  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  è **strongly** convex in  $C$  se  $\exists \tau > 0$ :

$$f(\alpha y + (1 - \alpha)x) \leq \alpha f(y) + (1 - \alpha)f(x) - \frac{\tau}{2} \alpha(1 - \alpha) \|y - x\|_2^2 \quad \forall x, y \in C, \quad \forall \alpha \in [0, 1]$$

### Teorema

$f$  è strongly convex **SSE**  $\exists \tau > 0$ :  $f(x) - \frac{\tau}{2} \|x\|_2^2$  è convessa

### Da cui segue che:

$f$  è strongly convex **SSE** esiste una funzione convessa  $\psi$  e  $\tau > 0$ :  $f(x) = \psi(x) + \frac{\tau}{2} \|x\|_2^2$

### Teorema - Convex

$f$  è convessa in  $C$  **SSE**  $f(y) \geq f(x) + (y - x)^T \nabla f(x) \quad \forall x, y \in C$

### Teorema - Strictly Convex

$f$  è strictly convex in  $C$  **SSE**  $f(y) > f(x) + (y - x)^T \nabla f(x) \quad \forall x, y \in C, \quad x \neq y$

### Teorema - Strongly Convex

$f$  è strongly convex in  $C$  **SSE**  $\exists \tau > 0$ :  $f(y) \geq f(x) + (y - x)^T \nabla f(x) + \frac{\tau}{2} \|y - x\|_2^2 \quad \forall x, y \in C$

### Teorema – Come capire i tipi di convessità •••

- $f$  è convessa in  $C$  **SSE**  $\forall x \in C$  la Hessiana  $\nabla^2 f(x)$  è **semi-definita positiva** ( $v^T \nabla^2 f(x) v \geq 0$ )  
Ovvero che gli autovalori  $\lambda$  di  $\nabla^2 f(x)$  sono:  $\lambda \geq 0 \quad \forall x \in C$
- Se  $\nabla^2 f(x) > 0 \quad \forall x \in C \rightarrow f$  è strictly convex
- $f$  è strongly convex in  $C$  **SSE**  $\exists \tau > 0$ :  $\nabla^2 f(x) - \tau I$  è **semi-definita positiva**  $\forall x \in C$ . Ovvero:  
 $v^T \nabla^2 f(x) v \geq \tau \|x\|_2^2 \quad \forall x \in C, \quad \forall v \in \mathbb{R}^n$   
Ovvero che gli autovalori  $\lambda$  di  $\nabla^2 f(x)$  sono:  $\lambda \geq \tau \quad \forall x \in C$

### Teoremi •••

- **SE**  $f$  è convessa e  $\alpha > 0 \rightarrow \alpha \cdot f$  è convessa
- **SE**  $f_1, f_2$  sono convesse  $\rightarrow f_1 + f_2$  è convessa
- **SE**  $f$  è convessa  $\rightarrow f(Ax + b)$  è convessa
- **SE**  $f_1 \cdots f_n$  sono convesse  $\rightarrow \max \{f_1(x), \dots, f_n(x)\}$  è convessa
- **SE**  $\{f_i\}_{i \in I}$  è una famiglia di funzioni convesse  $\rightarrow \sup_{i \in I} \{f_i(x)\}$  è convessa

### Teoremi

Siano  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  e  $g: \mathbb{R} \rightarrow \mathbb{R}$

- Se  $f$  è convessa e  $g$  è convessa non-decrescente  $\rightarrow f \circ g$  è convessa
- Se  $f$  è concava e  $g$  è convessa non-crescente  $\rightarrow f \circ g$  è convessa
- Se  $f$  è concava e  $g$  è concava non-decrescente  $\rightarrow f \circ g$  è concava
- Se  $f$  è convessa e  $g$  è concava non-crescente  $\rightarrow f \circ g$  è concava

### K-sublevel Set

Data una funzione  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  e dato  $k \in \mathbb{R}$  definiamo il  $k$  - sublevel set:

$$S_k(f) = \{x \in \mathbb{R}^n: f(x) \leq k\}$$

**Definizione – Quasi convex function**

Dato un set  $C \subseteq \mathbb{R}^n$ , la funzione  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  si definisce **quasi convessa** in  $C$  **SE** il set

$$S_k(f) \cap C = \{x \in C: f(x) \leq k\}$$

È convesso  $\forall k \in \mathbb{R}$ .

## PROBELI DI OTTIMIZZAZIONE - INTRO

### Problema Di Ottimizzazione

$$f_* = \min\{f(x): x \in X\} \rightarrow P$$

Con

$$f: \mathbb{R}^n \rightarrow \mathbb{R}$$
$$X := \{x \in \mathbb{R}^n: g_i(x) \leq 0, \quad i = 1 \dots m, \quad h_j(x) = 0, \quad j = 1 \dots p\} \subseteq \mathbb{R}^n$$

### Valore Ottimo

Il valore ottimo di  $P$  è definito come  $v(P) = \inf\{f(x): x \in X\}$ .  $v(P) \in \mathbb{R}$

### Ottimo Globale

$$x^* \in X : f(x^*) \leq f(x) \quad \forall x \in X$$

### Ottimo Locale

$$x^* \in X : f(x^*) \leq f(x) \quad \forall x \in B(x^*, r) \quad \forall r > 0$$

### Teorema di Weierstrass •••

Per  $f$  continua in  $X$  regione di ammissione chiusa e limitata  $\rightarrow$  Esiste (almeno) un ottimo globale

### Corollario 2

Se la funzione obiettivo  $f$  è continua e la regione di ammissione  $X$  è chiusa e  $\exists k \in \mathbb{R}$  tale che il  $k$  - *sublevel set*:  $S_k(f) = \{x \in X: f(x) \leq k\}$  è non-vuoto e limitato  $\rightarrow$  Esiste (almeno) un ottimo globale

### Funzione Coerciva

$$\lim_{\substack{\|x\| \rightarrow \infty \\ x \in X}} f(x) = +\infty$$

### Corollario 3

Se la funzione  $f$  è **continua** e **coerciva**, e  $X \neq \emptyset$  è chiuso  $\rightarrow$  Esiste (almeno) un ottimo globale

### Teorema 1 •••

Sia  $f$  **convessa** in  $X$  **convesso**  $\rightarrow$  Ogni ottimo locale di  $P$  è anche globale

### Proposizione 1

Sia  $f$  **strictly convex** in  $X$  **convesso**, e  $P$  ammette un ottimo globale  $x^*$   $\rightarrow x^*$  è l'unica soluzione ottima di  $P$

### Teorema 2

$f: \mathbb{R}^n \rightarrow \mathbb{R}$  è **strongly convex** in  $\mathbb{R}^n$  e  $X$  è **chiuso**  $\rightarrow$  Esiste un ottimo globale

### Corollario 1

$f: \mathbb{R}^n \rightarrow \mathbb{R}$  è **strongly convex** in  $\mathbb{R}^n$  e  $X$  è **chiuso** e **CONVESSO**  $\rightarrow$  Esiste un ottimo globale UNICO

### Teorema 3

Sia  $X$  **APERTO** e sia  $f$  **differenziabile** in  $x^* \in X$ . Se  $x^*$  è un ottimo locale per  $P$   $\rightarrow \nabla f(x^*) = 0$

**Teorema 4 - Second order necessary optimality condition**

Sia  $X$  aperto e  $x^* \in X$  ottimo locale per  $P \rightarrow 1) \nabla f(x^*) = 0. \quad 2) \nabla^2 f(x^*) \geq 0$

**Teorema 5 – Second order sufficient optimality condition**

Sia  $X$  aperto, preso  $x^* \in X$  assumiamo le seguenti condizioni vere

1)  $\nabla f(x^*) = 0$

2)  $\nabla^2 f(x^*) \geq 0$

$\rightarrow x^*$  è un ottimo locale per  $P$

**Teorema 6 – Optimality condition for convex problems**

Sia  $f$  differenziabile e convessa nel set  $X$  convesso e aperto  $\rightarrow x^* \in X$  è un ottimo globale per  $P$  **SSE**  $\nabla f(x^*) = 0$

**Teorema 7**

Sia  $f$  differenziabile e **STRICTLY CONVEX** nel set aperto e convesso  $X \rightarrow x^* \in X$  è un ottimo globale **UNICO** per  $P$  **SSE**  $\nabla f(x^*) = 0$

## METODI DI OTTIMIZZAZIONE PER PROBLEMI NON VINCOLATI

### Metodo del gradiente

- 1) Scegliere  $x_0 \in \mathbb{R}^n$ ,  $k = 0$
- 2) SE  $\nabla f(x_k) = 0$  ALLORA stop
- 3) ALTRIMENTI
  - a.  $d_k = -\nabla f(x_k)$
  - b.  $t_k \leftarrow \min_{t>0} f(x_k + t \cdot d_k)$
  - c.  $x_{k+1} = x_k + t_k \cdot d_k$
  - d.  $k = k + 1$
- 4) Step 2

### Proposizioni

Sia  $f$  continua e differenziabile

- 1)  $(d_k)^T d_{k+1} = 0$ ,  $\forall k$
- 2) SE  $\{x_k\} \rightarrow x^*$  ALLORA  $\nabla f(x^*) = 0$ . Ovvero  $x^*$  è un punto stazionario per  $f$

### Teorema

Se  $f$  è coerciva  $\rightarrow \forall x_0$  punto di partenza della sequenza  $\{x_k\} \rightarrow x^*$ , essa è limitata, e ogni punto di accumulo di  $\{x_k\}$  è un punto stazionario per  $f(x)$

### Corollario

Se  $f$  è coerciva e convessa  $\rightarrow \forall x_0$  punto di partenza della sequenza  $\{x_k\} \rightarrow x^*$ , essa è limitata, e ogni punto di accumulo di  $\{x_k\}$  è un minimo globale per  $f(x)$

### Corollario

Se  $f$  è stongly convex  $\rightarrow \forall x_0$  punto di partenza della sequenza  $\{x_k\}$ , essa converge all'unico minimo globale per  $f(x)$

### Metodo del gradiente – Caso Quadratico

Se  $f(x) = \frac{1}{2} x^T Q x + c^T x$ , con  $Q > 0$ .

Dove:  $g_k = \nabla f(x_k) = Q x_k + c$

Per cui  $t_k = -\frac{(d_k)^T \cdot g_k}{(d_k)^T \cdot Q \cdot d_k}$

### Metodo del gradiente con la linea di ricerca inesatta di Armijo

- 1) Scegliere  $\alpha, \gamma \in (0, 1)$ ,  $t' > 0$ ,  $x_0 \in \mathbb{R}^n$ ,  $k = 0$
- 2) SE  $\nabla f(x_k) = 0$  ALLORA stop
- 3) ALTRIMENTI
  - a.  $d_k = -\nabla f(x_k)$
  - b.  $t_k = t'$
  - c. while  $f(x_k + t_k \cdot d_k) > f(x_k) + \alpha t_k (d_k)^T \nabla f(x_k)$ 
    - i.  $t_k = \gamma t_k$
  - d.  $x_{k+1} = x_k + t_k \cdot d_k$
  - e.  $k = k + 1$
- 4) Step 2

### Metodo del gradiente coniugato

- 1) Settare  $x_0 \in \mathbb{R}^n$ ,  $k = 0$
- 2)  $g_0 = \nabla f(x_0) = Qx_0 + c$
- 3) SE  $g_k = \nabla f(x_k) = 0$  ALLORA stop
- 4) ALTRIMENTI
  - a. SE  $k = 0$  ALLORA  $d_k = -g_k$
  - b. ALTRIMENTI
    - i.  $\beta_k = \frac{(g_k)^T Q d_{k-1}}{(d_{k-1})^T Q d_{k-1}}$
    - ii.  $d_k = -g_k + \beta_k d_{k-1}$
  - c.  $t_k = -\frac{(g_k)^T d_k}{(d_k)^T Q d_k}$
  - d.  $x_{k+1} = x_k + t_k \cdot d_k$
  - e.  $g_{k+1} = Qx_{k+1} + c$
  - f.  $k = k + 1$
- 5) Step 3

### Proposizioni

- Un modo alternativo di calcolare  $t_k = \frac{\|g_k\|^2}{(d_k)^T Q d_k}$
- Un modo alternativo di calcolare  $\beta_k = \frac{\|g_k\|^2}{\|g_{k-1}\|^2}$
- Se non troviamo il minimo globale dopo  $k$  iterazioni  $\rightarrow \{g_1, g_2, \dots, g_k\}$  sono ortogonali
- Se non troviamo il minimo globale dopo  $k$  iterazioni  $\rightarrow \{d_1, d_2, \dots, d_k\}$  sono coniugate rispetto a  $Q$  e  $x_k$  è il minimo di  $f(x)$  su  $x_0 + \text{Span}(d_1, d_2, \dots, d_k)$

### Teorema

Il metodo del Gradiente Coniugato (CG) trova il minimo globale in, al massimo,  $n$  iterazioni

### Teorema

Se  $Q$  ha  $r$  autovalori distinti  $\rightarrow$  CG trova il minimo globale in, al massimo,  $r$  iterazioni

### Metodo di Newton – Basic Version

- 1) Settare  $x_0 \in \mathbb{R}^n$ ,  $k = 0$
- 2) SE  $\nabla f(x_k) = 0$  ALLORA stop
- 3) ALTRIMENTI
  - a.  $d_k \leftarrow \nabla^2 f(x_k) d = -\nabla f(x_k)$
  - b.  $x_{k+1} = x_k + d_k$
  - c.  $k = k + 1$
- 4) Step 2

### Teorema Di Convergenza

Se  $x^*$  è un minimo locale di  $f(x)$  e  $\nabla^2 f(x^*) > 0 \rightarrow \exists \delta > 0: \forall x_0 \in B(x^*, \delta)$  e la sequenza  $\{x_k\} \rightarrow x^*$  e

$$\|x_{k+1} - x^*\| \leq C \|x_k - x^*\|^2 \quad \forall k > k', \text{ per } C > 0 \text{ e } k' > 0$$



**Metodo di Newton – con linea di ricerca (inesatta)**

- 1) Settare  $\alpha, \gamma \in (0, 1)$ ,  $t' > 0$ ,  $x_0 \in \mathbb{R}^n$ ,  $k = 0$
- 2) SE  $\nabla f(x_k) = 0$  ALLORA stop
- 3) ALTRIMENTI
  - d.  $d_k \leftarrow \nabla^2 f(x_k) d = -\nabla f(x_k)$
  - e.  $t_k = t'$
  - f. while  $f(x_k + t_k \cdot d_k) > f(x_k) + \alpha t_k (d_k)^T \nabla f(x_k)$ 
    - i.  $t_k = \gamma t_k$
  - g.  $x_{k+1} = x_k + t_k d_k$
  - h.  $k = k + 1$
- 4) Step 2

**Teorema Di Convergenza**

Se  $f$  è strongly convex  $\rightarrow \forall x_0 \in \mathbb{R}^n$  la sequenza  $\{x_k\} \rightarrow x^*$  minimo globale di  $f(x)$

Se  $\alpha \in (0, 1/2)$  e  $t' = 1 \rightarrow$  la convergenza è quadratica

## PROBLEMI VINCOLATI

### Set Di Disequazioni Attive

Definiamo  $\mathcal{A}(x^*) = \{j: g_j(x^*) = 0\}$  il set di disequazioni attive  $x^* \in X$

### First Order Feasible Direction Cone

$$D(x^*) = \left\{ d \in \mathbb{R}^n: \begin{array}{l} d^T \nabla g_i(x^*) \leq 0 \quad \forall i \in \mathcal{A}(x^*) \\ d^T \nabla h_k(x^*) = 0 \quad \forall k = 1 \dots p \end{array} \right\}$$

### Definizione – Abadie Constraint Qualification (ACQ)

ACQ è valida per un punto ammissibile  $x^* \in X$  SE:  $T_X(x^*) = D(x^*)$

### Teoremi •••

#### 1) Vicoli Affini

SE  $g_j$  e  $h_k$  sono funzioni affini  $\forall j, k \rightarrow$  ACQ è verificata

#### 2) Slatex Condition

SE  $g_j$  è convessa  $\forall j = 1 \dots m$ , e  $h_k$  è affine  $\forall k = 1 \dots p$ , e  $\exists x' \in X: g(x') < 0$ ,  $h(x') = 0 \rightarrow$  ACQ è verificata  $\forall x \in X$

#### 3) Dipendenza lineare dei gradienti dei vincoli attivi

SE  $x^* \in X$  e i vettori

i.  $\nabla g_i(x^*) \leq 0, \forall i \in \mathcal{A}(x^*)$

j.  $\nabla h_k(x^*) = 0 \quad \forall k = 1 \dots p$

sono linearmente dipendenti  $\rightarrow$  ACQ è verificata in  $x^*$

### TEOREMA KKT •••

SE  $x^*$  è un minimo locale e SE l'ACQ è verificata  $\rightarrow \exists \lambda^* \in \mathbb{R}^n, \exists \mu^* \in \mathbb{R}^n : (x^*, \lambda^*, \mu^*)$  soluzione del sistema:

$$\begin{cases} \nabla f(x^*) + \sum_{i=1}^m \lambda_i^* \cdot \nabla g_i(x^*) + \sum_{j=1}^p \mu_j^* \cdot \nabla h_j(x^*) = 0 \\ \lambda_i^* \cdot g_i(x^*) = 0 & \forall i = 1 \dots m \\ \lambda_i^* \geq 0 \\ g(x^*) \leq 0 \\ h(x^*) = 0 \end{cases}$$

### LAGRANGIANA

$$L(x, \lambda, \mu) = f(x) + \sum_{i=1}^m \lambda_i \cdot g_i(x) + \sum_{j=1}^p \mu_j \cdot h_j(x) = 0$$

### KKT Con la lagrangiana

$$\begin{cases} \nabla_x L(x, \lambda, \mu) = 0. \\ \lambda_i \cdot g_i(x) = 0 \quad \forall i = 1 \dots m \\ \lambda_i \geq 0 \\ g(x) \leq 0 \\ h(x) = 0 \end{cases}$$

Con  $\lambda_i \cdot \nabla g_i(x) = 0$ , sostituibile con  $\lambda^T \cdot g(x) = 0$  o  $< \lambda, g(x) > = 0$

### Teorema – KKT per problemi convessi

SE il problema P è convesso e  $(\lambda^*, \mu^*, x^*)$  è la soluzione del KKT  $\rightarrow x^*$  è un ottimo globale

### Rilassamento Lagrangiano

$$\begin{cases} \inf( L(x, \lambda, \mu) ) \\ x \in \mathbb{R}^n \end{cases}$$

### Funzione duale Lagrangiana

$$\varphi(\lambda, \mu) := \inf( L(x, \lambda, \mu) )$$

- 1) Concava
- 2)  $\varphi(\lambda, \mu) \rightarrow -\infty$  per qualche punto
- 3)  $\varphi(\lambda, \mu)$  non differenziabile per qualche punto

### Teorema

$\forall \lambda \geq 0$  e  $\forall \mu \in \mathbb{R}^p \rightarrow \varphi(\lambda, \mu) \leq v(P)$  minimo globale per P

### Problema duale Lagrangiano

$$\begin{cases} \max ( \varphi(\lambda, \mu) ) \\ \lambda \geq 0 \end{cases} = D$$

D è per definizione **convesso** sempre.

### Teorema – Weak Duality

Per qualsiasi problema di ottimizzazione P vale che:  $v(D) \leq v(P)$

### Teorema – Strong Duality

Supponiamo che  $f$ ,  $g$  e  $h$  siano continue e differenziabili:

$$\begin{cases} \min f(x) \\ g(x) \leq 0 \\ h(x) = 0 \end{cases} = P$$

con P convesso,  $\exists x^*$  ottimo globale e l' ACQ è soddisfatto  $\rightarrow$

- 1) La Strong Duality è verificata:  $v(D) = v(P)$  e D ammette l'ottimo
- 2)  $(\lambda^*, \mu^*)$  è l'ottimo per D **SSE**  $(\lambda^*, \mu^*)$  è un vettore dei moltiplicatori KKT associato a  $x^*$

### Teorema

$(x^*, \lambda^*, \mu^*)$  è punto di **sella** per  $L(x, \lambda, \mu)$ , ovvero

$$L(x^*, \lambda, \mu) \leq L(x^*, \lambda^*, \mu^*) \leq L(x, \lambda^*, \mu^*) \quad \forall x \in \mathbb{R}^n, \quad \forall \lambda \in \mathbb{R}_+^m, \quad \forall \mu \in \mathbb{R}^p$$

**SSE**  $x^*$  è un ottimo per P, e  $(\lambda^*, \mu^*)$  è un ottimo per D, e vale  $v(D) = v(P)$

## SUPPORT VECTOR MACHINE

### Iperpiano Di Separazione

$$H = \{x \in \mathbb{R}^n : w^T x + b = 0\} : \begin{cases} w^T x_i + b > 0 & \forall x_i \in A \\ w^T x_i + b < 0 & \forall x_i \in B \end{cases}$$

Dove  $A$  e  $B$  sono i due labeled-set. Affinché  $H$  valga  $\text{conv}(A) \cup \text{conv}(B) = \emptyset$

### Funzione di Decisione

$$y_i = f(x) = \text{sign}(w^T x + b) = \begin{cases} 1 & \text{se } w^T x + b > 0 \\ -1 & \text{se } w^T x + b < 0 \end{cases} \leftarrow \text{classe}$$

### Definizione – Margine di Separazione

Se  $H$  è l'iperpiano di separazione dei due insiemi  $A$  e  $B$ , allora definiamo il margine di separazione di  $H$  come:

$$\rho(H) = \min_{x \in A \cup B} \frac{|w^T x + b|}{\|w\|}$$

### Teorema

Trovare l'iperpiano  $H$  che ha il massimo margine di separazione  $\rho(H)$  equivale a risolvere il seguente problema di programmazione quadratico convesso:

$$\begin{cases} \min_{w,b} \frac{1}{2} \|w\|^2 \\ w^T x_i + b > 1 & \forall x_i \in A \\ w^T x_i + b < -1 & \forall x_i \in B \end{cases}$$

### Linear SVM

$$\begin{cases} \min_{w,b} \frac{1}{2} \|w\|^2 \\ 1 - y_i(w^T x_i + b) \leq 0 & \forall x_i = 1, \dots, l \end{cases}$$

### Funzione Lagrangiana

$$L(x, b, \lambda) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^l \lambda_i y_i w^T x_i - b \sum_{i=1}^l \lambda_i y_i + \sum_{i=1}^l \lambda_i$$

- 1) **SE**  $\sum_{i=1}^l \lambda_i y_i \neq 0 \rightarrow \min_{w,b} L(x, b, \lambda) = -\infty$
- 2) **SE**  $\sum_{i=1}^l \lambda_i y_i = 0 \rightarrow L$  non dipende da  $b$ ,  
 $L$  è strongly convex,  
 $\nabla_w L(x, b, \lambda) = w - \sum_{i=1}^l \lambda_i y_i x_i = 0$

### Funzione Duale

$$\varphi(\lambda) = \begin{cases} -\infty & \text{se } \sum_{i=1}^l \lambda_i y_i \neq 0 \\ -\frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l y_i y_j x_i^T x_j \lambda_i \lambda_j + \sum_{i=1}^l \lambda_i & \text{se } \sum_{i=1}^l \lambda_i y_i = 0 \end{cases}$$

## Problema Duale

$$\begin{cases} \max_{\lambda} -\frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l y_i y_j x_i^T x_j \lambda_i \lambda_j + \sum_{i=1}^l \lambda_i & \text{OPPURE} & \max_{\lambda} -\frac{1}{2} \lambda^T X^T X \lambda + e^T \lambda \\ \sum_{i=1}^l \lambda_i y_i = 0 \\ \lambda \geq 0 \end{cases}$$

Con  $e^T = (1, \dots, 1)$  e  $X = \{y_1 x_1, \dots, y_l x_l\}$

- 1) Il duale è convesso:  $X^T X \geq 0$
- 2)  $\lambda^*$  ottimo del KKT associato all'ottimo del primale  $(w^*, b^*)$ , è ottimo anche del duale
- 3) **SE**  $\lambda_i^* > 0 \rightarrow x_i$  è detto **support vector**
- 4) **SE**  $\lambda_i^*$  è ottimo del duale  $\rightarrow w^* = \sum_{i=1}^l \lambda_i^* y_i x_i$
- 5)  $b^*$  è ottenuto da:  $\lambda_i^* (1 - y_i (w^{*T} x_i + b^*)) \rightarrow b^* = \frac{1}{y_i} - (w^*)^T x_i$

## Linear SVM con SOFT MARGIN

### Primale

$$\begin{cases} \min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l \xi_i \\ 1 - y_i (w^T x_i + b) \leq \xi_i & \forall i = 1, \dots, l \\ \xi_i \geq 0 & \forall i = 1, \dots, l \end{cases}$$

- 1) **SE**  $\xi_i > 1 \rightarrow$  il punto  $x_i$  è miss-classificato e  $\sum_{i=1}^l \xi_i$  è un limite superiore al numero di punti miss-classificati
  - a. **SE**  $x_i \in A$  e  $w^T x_i + b < 0 \rightarrow \xi_i > 1$  miss-classificato
  - b. **SE**  $x_i \in B$  e  $w^T x_i + b > 0 \rightarrow \xi_i > 1$  miss-classificato

### Duale

$$\begin{cases} \max_{\lambda} -\frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l y_i y_j x_i^T x_j \lambda_i \lambda_j + \sum_{i=1}^l \lambda_i \\ \sum_{i=1}^l \lambda_i y_i = 1 \\ 0 \leq \lambda_i \leq C \end{cases}$$

- 1) **SE**  $\lambda^*$  è una soluzione ottima di questo duale  $\rightarrow w^* = \sum_{i=1}^l \lambda_i^* y_i x_i$
- 2) Possiamo ottenere  $b^*$ , fissando  $0 \leq \lambda_i \leq C$ , e usando la condizione complementare (slackness):  $\begin{cases} \lambda_i^* [1 - y_i ((w^*)^T x_i + b^*) - \xi_i^*] = 0 \\ \mu_i^* \xi_i^* = (C - \lambda_i^*) \xi_i^* = 0 \end{cases}$  da cui:  $b^* = \frac{1}{y_i} - (w^*)^T x_i$
- 3)  $\xi_i^*$  è l'errore nel classificare il punto  $i$  -esimo
- 4) **SE**  $0 \leq \lambda_i^* < C \rightarrow \xi_i^* = 0$
- 5) **SE**  $0 < \lambda_i^* \leq C \rightarrow \xi_i^* = 1 - y_i ((w^*)^T x_i + b^*)$
- 6) **SE**  $\xi_i^* > 0 \rightarrow \lambda_i^* = C \rightarrow$  condizione necessaria per **mis-classificare**  $x_i$

## Non-Linear SVM

### Primale

$$\begin{cases} \min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l \xi_i \\ 1 - y_i(w^T \phi(x_i) + b) \leq \xi_i \quad \forall i = 1, \dots, l \\ \xi_i \geq 0 \quad \forall i = 1, \dots, l \end{cases}$$

### Duale

$$\begin{cases} \max_{\lambda} -\frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l y_i y_j \phi(x_i^T) \phi(x_j) \lambda_i \lambda_j + \sum_{i=1}^l \lambda_i \\ \sum_{i=1}^l \lambda_i y_i = 0 \\ \lambda \geq 0 \end{cases}$$
$$w^* = \sum_{i=1}^l \lambda_i^* y_i \phi(x_i)$$

Troviamo  $b^*$ , fissando  $0 < \lambda_i^* < C$ :

$$y_i \left[ \sum_{i=1}^l \lambda_i^* y_i \phi^T(x_i) \phi(x_i) + b^* \right] - 1 = 0$$

$$f(x) = \text{sign}((w^*)^T \phi(x_i) + b^*)$$

### Funzione Kernel

Definiamo  $k: \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}$ , la funzione kernel:  $k(x, y) = \langle \phi(x), \phi(y) \rangle$

### Teorema

Se  $k$  è una funzione Kernel, e se  $x_1, \dots, x_l \in \mathbb{R}^n \rightarrow$  la matrice  $K: k_{ij} = k(x_i, x_j) \geq 0$

Possiamo usare la funzione  $k$  per ridefinire il duale.

### In Pratica

- 1) Scegliere una funzione Kernel  $k$
- 2) Trovare la soluzione ottima del duale  $\lambda^*$
- 3) Scegliere  $i: 0 < \lambda_i^* < C$ , e trovare  $b^*$
- 4) Calcolare la decision function  $f(x)$

## REGRESSIONE

### Sistema per trovare il polinomio di regressione

$$\begin{cases} \min \|Az - y\| \\ z \in \mathbb{R}^n \end{cases}$$

$$\text{Dove: } A = \begin{pmatrix} 1 & x_1^1 & \cdots & x_1^{n-1} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_l^1 & \cdots & x_l^{n-1} \end{pmatrix} \in \mathbb{R}^{l \times n}, \quad y = \begin{pmatrix} y_1 \\ \vdots \\ y_l \end{pmatrix}, \quad z = \begin{pmatrix} z_1 \\ \vdots \\ z_n \end{pmatrix}$$

### Residual Vector

$$r \in \mathbb{R}^l: r_i = p(x_i) - y_i$$

Dove  $r$  è la differenza fra valore reale e valore predetto.

### Polinomio di regressione con $\|\bullet\|_2$

$$\begin{cases} \min \frac{1}{2} \|Az - y\|_2^2 \\ z \in \mathbb{R}^n \end{cases} = \frac{1}{2} z^T A^T A z - z^T A^T y + \frac{1}{2} y y^T$$

Con  $\text{rank}(A) = n$ ,  $A^T A > 0$

Soluzione:  $z = (A^T A)^{-1} A^T y$

### Polinomio di regressione con $\|\bullet\|_1$

$$\begin{cases} \min \frac{1}{2} \|Az - y\|_1 \\ z \in \mathbb{R}^n \end{cases} = \begin{cases} \min \sum_{i=1}^l u_i \\ u_i \geq A_i z - y_i \\ u_i \leq y_i - A_i z \end{cases}$$

Forma vettoriale:

$$\begin{cases} \min_{z,u} (\phi_n^T, e_n^T) \begin{pmatrix} z \\ u \end{pmatrix} \\ D \begin{pmatrix} z \\ u \end{pmatrix} \leq d \end{cases}$$

Con:

$$D = \begin{pmatrix} A & -I_l \\ -A & -I_l \end{pmatrix}, \quad d = \begin{pmatrix} y \\ -y \end{pmatrix}$$

### Polinomio di regressione con $\|\bullet\|_\infty$

$$\begin{cases} \min \|Az - y\|_\infty \\ z \in \mathbb{R}^n \end{cases} = \begin{cases} \min(u) \\ u_i \geq A_i z - y_i \\ u_i \leq y_i - A_i z \end{cases}$$

Forma vettoriale:

$$\begin{cases} \min_{z,u} (0, 0, \dots, 0, 1) \begin{pmatrix} z \\ u \end{pmatrix} \\ D \begin{pmatrix} z \\ u \end{pmatrix} \leq d \end{cases}$$

Con:

$$D = \begin{pmatrix} A & -I_l \\ -A & -I_l \end{pmatrix}, \quad d = \begin{pmatrix} y \\ -y \end{pmatrix}$$

## Regressione $\varepsilon$ – SV Lineare

$$\begin{cases} \min \left( \frac{1}{2} \|w\|^2 \right) \\ y_i \geq w^T x_i + b + \varepsilon \\ y_i \leq w^T x_i + b - \varepsilon \end{cases}$$

Forma vettoriale:

$$\begin{cases} \min_{z,u} \frac{1}{2} (w^T, b) Q \begin{pmatrix} w \\ b \end{pmatrix} \\ D \begin{pmatrix} w \\ b \end{pmatrix} \leq d \end{cases}$$

Con:

$$Q = \begin{pmatrix} I_l & \emptyset \\ \emptyset^T & \emptyset \end{pmatrix}, \quad D = \begin{pmatrix} -X & -e_l \\ X & e_l \end{pmatrix}, \quad d = \begin{pmatrix} \varepsilon e_l - y \\ \varepsilon e_l + y \end{pmatrix}$$

## Regressione $\varepsilon$ – SV Lineare con variabili di rilassamento (Slack Variables)

$$\begin{cases} \min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l (\xi_i^+, \xi_i^-) \\ y_i \leq w^T x_i + b + \varepsilon + \xi_i^+ \quad \forall i = 1, \dots, l \\ y_i \geq w^T x_i + b - \varepsilon - \xi_i^- \quad \forall i = 1, \dots, l \\ \xi_i^+, \xi_i^- \geq 0 \end{cases}$$

Forma vettoriale:

$$\begin{cases} \min_{z,u} \frac{1}{2} (w^T, b, (\xi_i^+)^T, (\xi_i^-)^T) Q_1 \begin{pmatrix} w \\ b \\ \xi_i^+ \\ \xi_i^- \end{pmatrix} + c^T \begin{pmatrix} w \\ b \\ \xi_i^+ \\ \xi_i^- \end{pmatrix} \\ D_1 \begin{pmatrix} w \\ b \\ \xi_i^+ \\ \xi_i^- \end{pmatrix} \leq d_1 \\ \xi_i^+ \geq 0 \\ \xi_i^- \geq 0 \end{cases}$$

Con:

$$Q_1 = \begin{pmatrix} I_n & 0_n & \emptyset_{n \times 2l} \\ 0_n^T & 0 & 0_{2l}^T \\ \emptyset_{2l \times n} & 0_{2l} & 1_{2l \times 2l} \end{pmatrix}, \quad D_1 = \begin{pmatrix} -x & -e_l & -I_l & \emptyset_{l \times l} \\ x & e_l & \emptyset_{l \times l} & -I_l \end{pmatrix}, \quad d = \begin{pmatrix} \varepsilon e_l - y \\ \varepsilon e_l + y \end{pmatrix}$$

## Lagrangiana $\varepsilon$ – SV Lineare (Slack Variables)

$$\begin{aligned} L(w, b, \xi^+, \xi^-, \lambda^+, \lambda^-, \eta^+, \eta^-) = \\ \frac{1}{2} \|w\|^2 - w^T \left[ \sum_{i=1}^l (\lambda_i^+ - \lambda_i^-) x_i \right] - b \sum_{i=1}^l (\lambda_i^+ - \lambda_i^-) + \sum_{i=1}^l \xi_i^+ (C - \lambda_i^+ - \eta_i^+) \\ + \sum_{i=1}^l \xi_i^- (C - \lambda_i^- - \eta_i^-) - \varepsilon \sum_{i=1}^l (\lambda_i^+ + \lambda_i^-) + \sum_{i=1}^l y_i (\lambda_i^+ - \lambda_i^-) \end{aligned}$$

- 1)  $\nabla_w L = w - \sum_{i=1}^l (\lambda_i^+ - \lambda_i^-) x_i = 0$
- 2)  $\nabla_b L = -\sum_{i=1}^l (\lambda_i^+ - \lambda_i^-) = 0$
- 3)  $\nabla_{\xi_i^\pm} L = C - \lambda_i^\pm - \eta_i^\pm = 0$



### Duale $\varepsilon$ – SV Lineare (Slack Variables)

$$\begin{cases} \max_{\lambda^+, \lambda^-} -\frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l (\lambda_i^+ - \lambda_i^-) (\lambda_j^+ - \lambda_j^-) (x_i)^T x_j - \varepsilon \sum_{i=1}^l (\lambda_i^+ + \lambda_i^-) + \sum_{i=1}^l y_i (\lambda_i^+ - \lambda_i^-) \\ \sum_{i=1}^l (\lambda_i^+ - \lambda_i^-) = 0 \\ \lambda_i^+ \in [0, C] \\ \lambda_i^- \in [0, C] \end{cases}$$

In formato vettoriale:

$$\begin{cases} \max_{\lambda^+, \lambda^-} -\frac{1}{2} ((\lambda^+)^T, (\lambda^-)^T) Q \begin{pmatrix} \lambda^+ \\ \lambda^- \end{pmatrix} + [-e(e_l^T, e_l^T) + (y^T, -y^T)] \begin{pmatrix} \lambda^+ \\ \lambda^- \end{pmatrix} \\ (e_l^T, -e_l^T) \begin{pmatrix} \lambda^+ \\ \lambda^- \end{pmatrix} = 0 \\ \lambda_i^+ \in [0, C] & i = 1, \dots, l \\ \lambda_i^- \in [0, C] & i = 1, \dots, l \end{cases}$$

Con:

$$Q = \begin{pmatrix} X & -X \\ -X & X \end{pmatrix}, \quad X = [(x_i)^T x_j] \quad \forall i, j = 1, \dots, l$$

1) È un problema **convesso** di programmazione quadratica

2) **SE**  $\lambda^+ > 0$  oppure  $\lambda^- > 0 \rightarrow x_i$  è un **support vector**

3) **SE**  $(\lambda^+, \lambda^-)$  ottimo del duale  $\rightarrow w = \sum_{i=1}^l (\lambda_i^+ - \lambda_i^-) x_i$

4)  $b$  è ottenuto tramite la *complementary condition*:

$$\begin{cases} \lambda_i^+ [\varepsilon + \xi_i^+ - y_i + w^T x_i + b] = 0 \\ \lambda_i^- [\varepsilon + \xi_i^- + y_i - w^T x_i - b] = 0 \\ \xi_i^+ (C - \lambda_i^+) = 0 \\ \xi_i^- (C - \lambda_i^-) = 0 \end{cases}$$

i.  $0 < \lambda^+ < C \rightarrow b = y_i - w^T x_i - \varepsilon$

ii.  $0 < \lambda^- < C \rightarrow b = y_i - w^T x_i + \varepsilon$

### Regressione $\varepsilon$ – SV NON Lineare

Definiamo:  $\phi: \mathbb{R}^n \rightarrow \mathcal{H}$ , spazio delle caratteristiche, e cerchiamo una regressione lineare in  $\{\phi(x_i), y_i\}$  nello spazio  $\mathcal{H} \times \mathbb{R}$ .

#### Primale

$$\begin{cases} \min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l (\xi_i^+, \xi_i^-) \\ y_i \geq w^T \phi(x_i) + b + \varepsilon + \xi_i^+ \\ y_i \leq w^T \phi(x_i) + b - \varepsilon - \xi_i^- \end{cases}$$

#### Duale

$$\begin{cases} \max_{\lambda^+, \lambda^-} -\frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l (\lambda_i^+ - \lambda_i^-)(\lambda_j^+ - \lambda_j^-) k(x_i, x_j) - \varepsilon \sum_{i=1}^l (\lambda_i^+ + \lambda_i^-) + \sum_{i=1}^l y_i (\lambda_i^+ - \lambda_i^-) \\ \sum_{i=1}^l (\lambda_i^+ - \lambda_i^-) = 0 \\ \lambda_i^+ \in [0, C] \\ \lambda_i^- \in [0, C] \end{cases}$$

Ricordando che  $k(x_i, x_j) = \phi(x_i)^T \phi(x_j)$

#### Passi

- 1) Scegliere una funzione kernel:  $k(x_i, x_j)$
- 2) Risolvendo il duale abbiamo:  $(\lambda^+, \lambda^-) \Rightarrow w = \sum_{i=1}^l (\lambda_i^+ - \lambda_i^-) \phi(x_i)$ 
  - a.  $w^T \phi(x_i) = \sum_{i=1}^l (\lambda_i^+ - \lambda_i^-) k(x_i, x_j)$
- 3) complementary condition: 
$$\begin{cases} \lambda_i^+ [y_i - f(x_i) - \varepsilon - \xi_i^+] = 0 \\ \lambda_i^- [y_i - f(x_i) + \varepsilon + \xi_i^-] = 0 \\ \xi_i^+ (C - \lambda_i^+) = 0 \\ \xi_i^- (C - \lambda_i^-) = 0 \end{cases}$$
- 4)  $0 < \lambda^+ < C \Rightarrow b = y_i - w^T \phi(x_i) - \varepsilon = y_i - \sum_{i=1}^l (\lambda_i^+ - \lambda_i^-) k(x_i, x_j) - \varepsilon$
- 5)  $0 < \lambda^- < C \Rightarrow b = y_i - w^T \phi(x_i) + \varepsilon = y_i - \sum_{i=1}^l (\lambda_i^+ - \lambda_i^-) k(x_i, x_j) + \varepsilon$

#### Funzione di regressione per $\varepsilon$ – SV NON Lineare

$$f(x) = w^T \phi(x_i) + b = \sum_{i=1}^l (\lambda_i^+ - \lambda_i^-) k(x_i, x_j) + b$$

## CLUSTER

### Modello

$$\begin{cases} \min \sum_{i=1}^l \min_{j=1, \dots, k} d(p_i, x_j) \\ x_j \in \mathbb{R}^n \quad \forall j = 1, \dots, k \end{cases} : M$$

Dove  $d(p_i, x_j)$  è la distanza fra il punto  $p_i$  e il centroide  $x_j$

### Problema di Clustering

- 1) **SE**  $k = 1$  il problema è convesso
- 2) **SE**  $k > 1$  il problema è non convesso e non differenziabile

### Teorema

Il problema  $\begin{cases} \min \sum_{i=1}^l \min_{j=1, \dots, k} \|p_i - x_j\|_2^2 \\ x_j \in \mathbb{R}^n \quad \forall j = 1, \dots, k. \end{cases}$  è equivalente al seguente problema non convesso e non differenziabile:

$$\begin{cases} \min_{x, \alpha} f(x, \alpha) := \sum_{i=1}^l \sum_{j=1}^k \alpha_{ij} \|p_i - x_j\|_2^2 \\ \sum_{j=1}^k \alpha_{ij} = 1 \quad \forall i = 1, \dots, l \\ \alpha_{ij} \geq 0 \quad \forall i = 1, \dots, l \quad \forall j = 1, \dots, k. \\ x_j \in \mathbb{R}^n \quad \forall j = 1, \dots, k \end{cases} : C_2$$

### K-Means

- 1) Inizializzazione
  - a. Set  $t = 0$
  - b. Setta i centroidi  $x_1^0 \dots x_k^0$
  - c. Setta  $\alpha_{ij}^0 = \begin{cases} 1 & j: \|p_i - x_j\|_2 = \min_{h=1, \dots, k} \|p_i - x_h^0\|_2 \\ 0 & \text{altrimenti} \end{cases}$
  - i.  $\forall i = 1 \dots l$
- 2) Aggiornamento centroidi
  - a.  $\forall j = 1, \dots, k. \quad x_j^{t+1} = \frac{\sum_{i=1}^l \alpha_{ij}^t \cdot p_i}{\sum_{i=1}^l \alpha_{ij}^t}$
- 3) Aggiornamento clusters
  - a.  $\forall i = 1, \dots, l. \quad \alpha_{ij}^{t+1} = \begin{cases} 1 & j: \|p_i - x_j^{t+1}\|_2 = \min_{h=1, \dots, k} \|p_i - x_h^{t+1}\|_2 \\ 0 & \text{altrimenti} \end{cases}$
- 4) Stopping condition
  - a. Se  $f(x^{t+1}, \alpha^{t+1}) = f(x^t, \alpha^t) \rightarrow \text{STOP}$
  - b. Altrimenti  $t++$  e vai al passo 2

**Teorema**

L'algoritmo di K-Means termina dopo un numero finito di iterazioni in una soluzione  $(x^*, \alpha^*)$  del sistema  $KKT$  del problema  $C_2$  tale che

$$\begin{aligned} f(x^*, \alpha^*) &\leq f(x^*, \alpha) & \forall \alpha \geq 0: \sum_{j=1}^k \alpha_{ij} &= 1. \quad \forall i = 1, \dots, l \\ f(x^*, \alpha^*) &\leq f(x, \alpha^*) & \forall x \in \mathbb{R}^{kl} \end{aligned}$$

**Teorema  $\|\bullet\|_1$** 

Il problema  $\begin{cases} \min \sum_{i=1}^l \min_{j=1, \dots, k} \|p_i - x_j\|_1 \\ x_j \in \mathbb{R}^n \quad \forall j = 1, \dots, k \end{cases}$  è equivalente al seguente problema non convesso e non differenziabile:

$$\begin{cases} \min_{x, \alpha} f(x, \alpha) := \sum_{i=1}^l \sum_{j=1}^k \alpha_{ij} \|p_i - x_j\|_1 \\ \sum_{j=1}^k \alpha_{ij} = 1 & \forall i = 1, \dots, l \\ \alpha_{ij} \geq 0 & \forall i = 1, \dots, l \quad \forall j = 1, \dots, k \\ x_j \in \mathbb{R}^n & \forall j = 1, \dots, k \end{cases} : C_1$$

**Teorema  $\bullet\bullet\bullet$** 

Il problema  $C_1$  è equivalente al seguente problema non convesso e non differenziabile:

$$\begin{cases} \min_{x, \alpha, u} \sum_{i=1}^l \sum_{j=1}^k \sum_{h=1}^n \alpha_{ij} u_{ijk} \\ u_{ijk} \geq (p_i)_h - (x_j)_h & \forall i = 1, \dots, l, \quad \forall j = 1, \dots, k, \quad \forall h = 1, \dots, n \\ u_{ijk} \geq (x_j)_h - (p_i)_h & \forall i = 1, \dots, l, \quad \forall j = 1, \dots, k, \quad \forall h = 1, \dots, n \\ \sum_{j=1}^k \alpha_{ij} = 1 & \forall i = 1, \dots, l \\ \alpha_{ij} \geq 0 & \forall i = 1, \dots, l, \quad \forall j = 1, \dots, k \\ x_j \in \mathbb{R}^n & \forall j = 1, \dots, k. \end{cases}$$

## K-Median

- 1) Inizializzazione
  - a. Set  $t = 0$
  - b. Setta i centroidi  $x_1^0 \dots x_k^0$
  - c. Setta  $\alpha_{ij}^0 = \begin{cases} 1 & j: \|p_i - x_j\|_1 = \min_{h=1, \dots, k} \|p_i - x_h^0\|_1 \\ 0 & \text{altrimenti} \end{cases}$ 
    - i.  $\forall i = 1 \dots l$
- 2) Aggiornamento centroidi
  - a.  $\forall j = 1, \dots, k. \quad x_j^{t+1} = \text{mediano}(p_i: \alpha_{ij}^t = 1)$
- 3) Aggiornamento clusters
  - a.  $\forall i = 1, \dots, l. \quad \alpha_{ij}^{t+1} = \begin{cases} 1 & j: \|p_i - x_j^{t+1}\|_1 = \min_{h=1, \dots, k} \|p_i - x_h^{t+1}\|_1 \\ 0 & \text{altrimenti} \end{cases}$
- 4) Stopping condition
  - a. Se  $f(x^{t+1}, \alpha^{t+1}) = f(x^t, \alpha^t) \rightarrow \text{STOP}$
  - b. Altrimenti  $t++$  e vai al passo 2

## Teorema

L'algoritmo di K-Median termina dopo un numero finito di iterazioni in una soluzione  $(x^*, \alpha^*)$  punto stazionario tale che:

$$\begin{aligned} f(x^*, \alpha^*) &\leq f(x^*, \alpha) & \forall \alpha \geq 0: \sum_{j=1}^k \alpha_{ij} &= 1. \quad \forall i = 1, \dots, l \\ f(x^*, \alpha^*) &\leq f(x, \alpha^*) & \forall x \in \mathbb{R}^{kl} \end{aligned}$$

## METODI PER PROBLEMI DI OTTIMIZZAZIONE VINCOLATI

### (Exact) Penalty Method

Trasformiamo il problema  $P$  (convesso, e sono con le  $g_i(x)$ ) in un problema senza vincoli aggiungendo una penalità a  $f$

$$\begin{cases} \min f(x) + \frac{1}{\varepsilon} \rho(x) := \rho_\varepsilon(x) \\ x \in \mathbb{R}^n \end{cases} = P_\varepsilon$$

Dove

$$\rho(x) = \sum_{i=1}^m (\max\{0, g_i(x)\})^2$$

### Proposizione

- 1) SE  $f$  e  $g_i$  sono continue e differenziabili  $\rightarrow$  anche  $\rho_\varepsilon$  lo è, e il gradiente è:

$$\nabla \rho_\varepsilon(x) = \nabla f(x) + \frac{2}{\varepsilon} \sum_{i=1}^m \max\{0, g_i(x)\} \nabla g_i(x)$$

- 2) SE  $f$  e  $g_i$  sono convesse  $\rightarrow$  anche  $\rho_\varepsilon$  lo è  
3) Ogni problema  $P_\varepsilon$  ha una relazione con  $P \rightarrow v(P_\varepsilon) \leq v(P) \quad \forall \varepsilon > 0$   
4) SE  $x_\varepsilon^*$  risolve il problema  $P_\varepsilon \rightarrow x_\varepsilon^*$  è ottimo anche per  $P$   
5) SE  $0 < \varepsilon_2 < \varepsilon_1 \rightarrow v(P_{\varepsilon_1}) \leq v(P_{\varepsilon_2})$

### Passi del metodo

- 1) Settare  $\varepsilon_0 > 0$
- 2) Settare  $\tau \in (0, 1)$
- 3) Settare  $k = 0$
- 4) Trovare l'ottimo  $x_k$  del problema  $P_{\varepsilon_k}$
- 5) SE  $x_k \in X$ 
  - a. STOP
- 6) ALTIMENTI
  - a.  $\varepsilon_{k+1} = \tau \varepsilon_k$
  - b.  $k++$
  - c. Passo 1

### Teoremi

- SE  $f$  è coerciva  $\rightarrow \exists \{x_k\}$ , sequenza limitata, e ogni punto stazionario è un'ottima soluzione di  $P$
- SE  $\{x_k\} \rightarrow x^* \rightarrow x^*$  è un'ottima soluzione di  $P$
- SE  $\{x_k\} \rightarrow x^*$  e i gradienti dei vincoli attivi sono linearmente indipendenti  $\rightarrow x^*$  è un'ottima soluzione di  $P$  e la sequenza  $\{\lambda_k\} : \lambda_k^i = \frac{2}{\varepsilon} \max\{0, g_i(x_k)\} \rightarrow \lambda^*$  vettore dei moltiplicatori del KKT associati a  $x^*$

(In quello esatto, dato che il problema  $P$  convesso, abbiamo una sola soluzione e quindi un unico  $\varepsilon$ .)

## Barrier Method

Questo metodo cerca una sequenza di punti ammissibili che approssima la soluzione ottima di  $P$ , problema vincolato, approssimandolo con:

$$\begin{cases} \min f(x) - \varepsilon \sum_{i=1}^m \log(-g_i(x)) = \psi_\varepsilon(x) \\ x \in \text{int}(X) \end{cases} \quad := P_B$$

**Proprietà di  $B(x) = \sum_{i=1}^m \log(-g_i(x))$**

1)  $\text{dom}(B) = \text{int}(X)$

2)  $B$  convesso

3)  $B$  derivabile con:

a.  $\nabla B(x) = -\sum_{i=1}^m \frac{1}{g_i(x)} \nabla g_i(x)$

b.  $\nabla^2 B(x) = \sum_{i=1}^m \frac{1}{[g_i(x)]^2} \nabla g_i(x) \nabla g_i(x)^T + \sum_{i=1}^m \frac{1}{-g_i(x)} \nabla^2 g_i(x)$

## Passi del metodo

1) Settare  $\delta > 0$

2) Settare  $\varepsilon_1 > 0$

3) Settare  $\tau \in (0, 1)$

4) Scegliere  $x_0$

5) Settare  $k = 1$

6) Trovare l'ottimo  $x_k$  del problema  $P_B$

a. Partendo da  $x_{k-1}$

7) **SE**  $m \varepsilon_k < \delta$

a. **STOP**

8) **ALTRIMENTI**

a.  $\varepsilon_{k+1} = \tau \varepsilon_k$

b.  $k++$

c. Passo 1

## Trovare $x_0$

Consideriamo il problema ausiliare:

$$\begin{cases} \min s \\ g_i(x) < s \quad \forall i = 1, \dots, m \end{cases}$$

1) Prendiamo  $\tilde{x} \in \mathbb{R}^n$ , e cerchiamo  $s^* > \max_{i=1, \dots, m} g_i(\tilde{x}) \rightarrow (\tilde{x}, s^*)$

2) Cercare la soluzione ottima dell'ausiliare:  $(x^*, s^*)$  usando un Barrier Method

3) **SE**  $s^* < 0 \rightarrow x^* \in \text{int}(X)$

a. **ALTRIMENTI**  $\text{int}(X) = \emptyset$

## PROBLEMI MULTI OBIETTIVO

### Definizione

$$\begin{cases} \min f(x) = (f_1(x), \dots, f_s(x)) \\ x \in X \end{cases}$$

### Ordine di Pareto

Dati  $x, y \in \mathbb{R}^s$

$$x \geq y \iff x_i \geq y_i \quad \forall i = 1, \dots, s$$

- 1) Reflexive:  $x \geq x$
- 2) Asimmetrico: se  $x \geq y$  e  $y \geq x \rightarrow x = y$
- 3) Transitiva: se  $x \geq y$  e  $y \geq z \rightarrow x \geq z$

### Minimi di Pareto per un Sottoinsieme

#### 1) Ideal Minimum

- a.  $x^* \in A$  è un  $IMin(A)$  se  $y \geq x^*, \forall y \in A$
- b.  $x^* \in A$  è un  $IMin(A)$  se  $A \subseteq (x^* + \mathbb{R}_+^s)$

#### 2) Minimum

- a.  $x^* \in A$  è un  $Min(A)$  se  $\nexists y \in A, y \neq x^*, x^* \geq y$
- b.  $x^* \in A$  è un  $Min(A)$  se  $A \cap (x^* - \mathbb{R}_+^s) = \emptyset$

#### 3) Weak Minimum

- a.  $x^* \in A$  è un  $WMin(A)$  se  $\nexists y \in A, y \neq x^*, x^* > y$
- b.  $x^* \in A$  è un  $WMin(A)$  se  $A \cap (x^* - \text{int}(\mathbb{R}_+^s)) = \emptyset$

### Preposizione

Se  $IMin(A) \neq \emptyset \rightarrow IMin(A) = Min(A) = \{x^*\}$

### Teorema – Esistenza del minimo

Se  $\exists x^* \in A: A \cap (x^* - \mathbb{R}_+^s)$  è compatto  $\rightarrow Min(A) \neq \emptyset$

### Minimi di Pareto per un problema multi-obiettivo $P$ •••

#### 1) Ideal Minimum

- a.  $x^* \in X$  è un  $IMin(P)$  se  $f(x^*) = IMin(f(X))$  ovvero se  $f(x) \geq f(x^*), \forall x \in X$

#### 2) Minimum

- a.  $x^* \in X$  è un  $Min(P)$  se  $f(x^*) = Min(f(X))$  ovvero che  $\nexists x \in X$ :
  - i.  $f_i(x^*) \geq f_i(x), \forall i = 1, \dots, s$
  - ii.  $f_j(x^*) > f_j(x)$ . Per qualche  $j \in \{1, \dots, s\}$

#### 3) Weak Minimum

- a.  $x^* \in X$  è un  $WMin(P)$  se  $f(x^*) = WMin(f(X))$  ovvero che:
  - i.  $\nexists x \in X: f_i(x^*) > f_i(x), \forall i = 1, \dots, s$

### Teorema •••

Se  $f_i$  è continua  $\forall i = 1, \dots, s$  e se  $X$  è compatto  $\rightarrow \exists Min(P)$

### Teorema •••

Se  $f_i$  è continua  $\forall i = 1, \dots, s$  e se  $X$  è chiuso, e se  $\exists v \in \mathbb{R}, \exists j = 1, \dots, s$ :

$$\{x \in X: f_j(x) \leq v\}$$

è un insieme non vuoto e limitato  $\rightarrow \exists Min(P)$



**Corollario**

Se  $f_i$  è continua  $\forall i = 1, \dots, s$  e se  $X$  è chiuso, con  $f_j$  coerciva per qualche  $j \in \{1, \dots, s\}$

$\rightarrow \exists \text{Min}(P)$

**Teorema**

$x^* \in X$  è un  $\text{Min}(P)$  **SSE** il problema ausiliario  $P_a$  ha soluzione 0

$$\begin{cases} \max \sum_{i=1}^s \varepsilon_i \\ f_i(x) + \varepsilon_i \leq f_i(x^*). \quad \forall i = 1, \dots, s \\ x \in X \\ \varepsilon \geq 0 \end{cases} := P_a$$

**Teorema**

$x^* \in X$  è un  $\text{WMin}(P)$  **SSE** il problema ausiliario  $P_{wa}$  ha soluzione 0

$$\begin{cases} \max v \\ v \leq \varepsilon_i & \forall i = 1, \dots, s \\ f_i(x) + \varepsilon_i \leq f_i(x^*). & \forall i = 1, \dots, s \\ x \in X \\ \varepsilon \geq 0 \end{cases} := P_{wa}$$

## PROBLEMI MULTI OBIETTIVO NON VINCOLATI

### Definizione problema

$$\begin{cases} \min f(x) = (f_1(x), \dots, f_s(x)) \\ x \in \mathbb{R}^n \end{cases} \quad := P_u$$

con  $f_i$  continua e differenziabile  $\forall i = 1, \dots, s$

### Teorema

**SE**  $x^* \in X$  è un  $Min(P_u)$   $\Rightarrow$  il problema  $S_1$  non ha soluzione.

$$\begin{cases} \nabla f_i(x^*)^T d < 0, \quad \forall i = 1, \dots, s \\ d \in \mathbb{R}^n \end{cases} \quad := S_1$$

### Condizione Necessaria di Ottimalità

**SE**  $x^* \in X$  è un  $WMin(P_u)$   $\Rightarrow \exists \theta^* \in \mathbb{R}^s$ :  $(x^*, \theta^*)$  è una soluzione di:

$$\begin{cases} \sum_{i=1}^s \theta_i \nabla f_i(x^*) = 0 \\ \theta \geq 0 \\ \sum_{i=1}^s \theta_i = 1 \\ x \in \mathbb{R}^n \end{cases} \quad := S$$

### Condizione Sufficiente di Ottimalità

**SE**  $P_u$  è convesso (Ovvero ogni  $f_i$  è convessa) e  $(x^*, \theta^*)$  è l'ottimo per  $S$   $\Rightarrow$

1)  $x^* = WMin(P_u)$

2) **SE** vale anche  $\theta^* > 0 \Rightarrow x^* = Min(P_u)$

## PROBLEMI MULTI OBIETTIVO VINCOLATI

### Definizione problema

$$\begin{cases} \min f(x) = (f_1(x), \dots, f_s(x)) \\ x \in X = \{x \in \mathbb{R}^n: g_j(x) \leq 0, h_k(x) = 0\} \end{cases} := P$$

$$\forall j = 1, \dots, m \text{ e } \forall k = 1, \dots, p$$

### Teorema KKT Multi-Obiettivo

**SE**  $x^*$  è un  $WMin(P)$  e **SE** l'ACQ è verificata in  $x^* \rightarrow \exists \theta^* \in \mathbb{R}^s, \exists \lambda^* \in \mathbb{R}^m, \exists \mu^* \in \mathbb{R}^p :$   
 $(x^*, \theta^*, \lambda^*, \mu^*)$  è soluzione del sistema:

$$\begin{cases} \sum_{i=1}^s \theta_i \cdot \nabla f_i(x) + \sum_{j=1}^m \lambda_j \cdot \nabla g_j(x) + \sum_{k=1}^p \mu_k \cdot \nabla h_k(x) = 0 \\ \theta \geq 0 \\ \sum_{i=1}^s \theta_i = 1 \\ \lambda \geq 0 \\ \lambda_j \cdot \nabla g_j(x) = 0. & \forall j = 1, \dots, m \\ g(x^*) \leq 0 \\ h(x^*) = 0 \end{cases}$$

### Teorema – Condizione Necessaria di Ottimalità

**SE**  $x^* \in X$  è un  $WMin(P) \rightarrow$  il problema  $S$  non ha soluzione.

$$\begin{cases} \nabla f_i(x^*)^T d < 0. & \forall i = 1, \dots, s. \\ d \in T_X(x^*) \end{cases} := S$$

### Corollario

**SE**  $x^*$  è un  $WMin(P)$  e **SE** l'ACQ è verificata in  $x^*$  il problema  $S_1$  non ha soluzione.

$$\begin{cases} v^T \nabla f_i(x^*)^T d < 0. & \forall i = 1, \dots, s \\ v^T \nabla g_j(x^*)^T d \leq 0. & \forall j = 1, \dots, m \\ v^T \nabla h_k(x^*)^T d < 0. & \forall k = 1, \dots, p \\ v \in \mathbb{R}^n \end{cases} := S_1$$

### Teorema – Condizione Sufficiente di Ottimalità

Assunti  $f_i$  e  $g_j$  sono convesse  $\forall i$  e  $\forall j$ , e  $h_k$  è affine  $\forall k$ :

- 1) **SE**  $(x^*, \theta^*, \lambda^*, \mu^*)$  risolve il KKT  $\rightarrow x^* = WMin(P)$
- 2) **SE**  $(x^*, \theta^*, \lambda^*, \mu^*)$  risolve il KKT e  $\theta^* > 0 \rightarrow x^* = Min(P)$

### Proposizione

**SE**  $x^*$  è un unico minimo globale per  $f_k$  in  $X$ , per qualche  $k = 1, \dots, s \rightarrow x^* = Min(P)$

## SCALARIZATION METHOD

Associamo al problema  $P$  vincolato, il sistema  $P_\alpha$  che associa pesi a ogni  $f_i$ :

$$\begin{cases} \min \sum_{i=1}^s \alpha_i f_i(x) \\ x \in X \end{cases} := P_\alpha$$

Con  $S_\alpha$  insieme delle soluzioni ottime di  $P_\alpha$

$$\alpha \geq 0, \quad \sum_{i=1}^s \alpha_i = 1$$

### Teorema

- $\bigcup_{\alpha \geq 0} S_\alpha \subseteq \{WMin(P)\}$
- $\bigcup_{\alpha > 0} S_\alpha \subseteq \{Min(P)\}$

### Teorema

**SE** che  $X$  è convesso e che  $f_i$  sono convesse in  $X$ ,  $\forall i = 1, \dots, s \rightarrow$

$$\bigcup_{\alpha \geq 0} S_\alpha = \{WMin(P)\}$$

### Teorema

Sia  $P$  è lineare (ovvero che  $f_i$  è lineare  $\forall i = 1, \dots, s$ ) e sia  $X$  un poliedro  $\rightarrow$

- $\bigcup_{\alpha \geq 0} S_\alpha = \{WMin(P)\}$
- $\bigcup_{\alpha > 0} S_\alpha = \{Min(P)\}$

### Proposizione

**SE**  $x^*$  è un unico minimo globale per  $P_\alpha$ , per qualche  $\alpha$ ,  $\rightarrow x^* = Min(P)$

### NOTA

Solo con  $\alpha = 0$  si hanno  $WMin(P)$ , gli altri sono  $Min(P)$  di Pareto; tranne che se con  $\alpha = 0$  la funzione che rimane è strongly convex

### NOTA

**SE** l'ottimo di  $P_\alpha$  coincide sia con  $\alpha = 0$  che con  $\alpha = 1 \rightarrow x^* = IMin(P)$  perché minimizza entrambe le funzioni obiettivo

## GOAL METHOD

Definiamo nello spazio obiettivo  $\mathbb{R}^s$  un punto ideale  $z$ , così definito:

$$z_i = \min_{x \in X} f_i(x). \quad \forall i = 1, \dots, s.$$

### Teorema

Per avvicinarsi il più possibile a  $z$ , risolviamo:

$$\left\{ \min_{x \in X} \|f(x) - z\|_q \quad \text{con } q \in [1, +\infty] \right\} := G$$

- SE  $q \in [1, +\infty) \rightarrow$  ogni soluzione ottima di  $G$  è un  $Min(P)$
- SE  $q = +\infty \rightarrow$  ogni soluzione ottima di  $G$  è un  $WMin(P)$

### Goal Method – Norma 2

$$\left\{ \min_{x \in X} \frac{1}{2} \|Cx - z\|_2^2 = \frac{1}{2} x^T C^T C x - x^T C^T z + \frac{1}{2} z^T z \right\} := G_2$$

## GAME THEORY – Matrix Game

### Definizione two-person non-cooperative game

$$P_1 \rightarrow \min_{x \in X} f_1(x, y), \quad P_2 \rightarrow \min_{y \in Y} f_2(x, y)$$

### Equilibrio di Nash

In un two-person non-cooperative game, una coppia di strategie  $(x^*, y^*)$  è detta Equilibrio di Nash **SE**

$$f_1(x^*, y^*) = \min_{x \in X} f_1(x, y^*), \quad f_2(x^*, y^*) = \min_{y \in Y} f_2(x^*, y)$$

### Matrix Game

In un two-person non-cooperative game, dove:

- $X$  e  $Y$  sono set finiti:  $X = \{1, \dots, m\}$ ,  $Y = \{1, \dots, n\}$
- $f_1 = -f_2$  (zero-sum game)

definiamo la Matrix Game  $C: c_{ij} = f_1(i, j)$

### Definizione – Strategia Strictly Dominated

Dato un two-person non-cooperative game, una strategia  $x \in X$  è strettamente dominata da  $x^* \in X$  se:

$$f_1(x, y) > f_1(x^*, y) \quad \forall y \in Y$$

Similmente  $y \in Y$  è strettamente dominata da  $y^* \in Y$  se:

$$f_2(x, y) > f_2(x, y^*) \quad \forall x \in X$$

Le strategie dominate possono essere eliminate dal gioco

### Mixed Strategies

**SE**  $C$  è un Matrix Game  $m \times n \rightarrow$

- una Mixed Strategy per il giocatore 1 è un vettore grande  $m$  contenete probabilità.

$$X = \{x \in \mathbb{R}^m: x \geq 0, \sum_{i=1}^m x_i = 1\}$$

- una Mixed Strategy per il giocatore 2 è un vettore grande  $n$  contenete probabilità.

$$Y = \{y \in \mathbb{R}^n: y \geq 0, \sum_{j=1}^n y_j = 1\}$$

### Pure Strategy

Sono i vertici di  $X$  e  $Y$ :  $e_i = (0, \dots, 0, 1, 0, \dots, 0)$

### Expected Cost

$$f_1(x, y) = x^T C y, \quad f_2(x, y) = -x^T C y$$

### Nota

$$x^T C y = \sum_{i=1}^m \sum_{j=1}^n x_i c_{ij} y_j$$

### Mixed Strategies Nash Equilibrium

SE  $C$  è un Matrix Game  $m \times n \rightarrow (x^*, y^*) \in X \times Y$  è un Mixed Strategies Nash Equilibrium **SE**

$$\max_{y \in Y} (x^*)^T C y = (x^*)^T C y^* = \max_{x \in X} x^T C (y^*)$$

O equivalentemente:

$$(x^*)^T C y \leq (x^*)^T C y^* \leq x^T C (y^*) \quad \forall (x, y) \in X \times Y$$

$(x^*, y^*)$  è un **punto di sella** per  $f_1(x, y) = x^T C y$  su  $X \times Y$

### Punto Di Sella

Sia  $X \subseteq \mathbb{R}^m$  e  $Y \subseteq \mathbb{R}^n$ .  $(x^*, y^*)$  è un punto di sella della funzione  $F: X \times Y \rightarrow \mathbb{R}$  **SE**

$$F(x^*, y) \leq F(x^*, y^*) \leq F(x, y^*), \quad \forall (x, y) \in X \times Y$$

### Teorema

$(x^*, y^*) \in X \times Y$  soddisfa la condizione di punto di sella **SSE**

1)  $x^*$  è una soluzione ottima di:  $\min_{x \in X} (\sup_{y \in Y} F(x, y))$

2)  $y^*$  è una soluzione ottima di:  $\max_{y \in Y} (\inf_{x \in X} F(x, y))$

3)  $\sup_{y \in Y} F(x, y) = \inf_{x \in X} F(x, y)$

Tutte e tre le condizioni sono equivalenti a:  $\min_{x \in X} (\sup_{y \in Y} F(x, y)) = \max_{y \in Y} (\inf_{x \in X} F(x, y)) = F(x^*, y^*)$

### Teorema – Esistenza del punto di sella

Sia  $X \subseteq \mathbb{R}^m$  e  $Y \subseteq \mathbb{R}^n$ . Assumendo che

1)  $X$  e  $Y$  sono non vuoti, convessi e compatti

2)  $F(\bullet, y)$  è continua e quasi-convessa in  $X, \forall y \in Y$

3)  $F(x, \bullet)$  è continua e quasi-convessa in  $Y, \forall x \in X$

$\rightarrow F$  ammette un punto di sella in  $X \times Y$

### Corollario

1) Ogni Matrix Game ha almeno un Mixed Strategies Nash Equilibrium

2)  $(x^*, y^*)$  è un Mixed Strategies Nash Equilibrium **SSE**

$$\begin{cases} x^* \text{ è una soluzione ottima di: } \min_{x \in X} (\max_{y \in Y} x^T C y) \\ y^* \text{ è una soluzione ottima di: } \max_{y \in Y} (\min_{x \in X} x^T C y) \end{cases}$$

Con valore ottimo pari a  $(x^*)^T C y^*$

### Teorema

Il problema  $\min_{x \in X} (\max_{y \in Y} x^T C y)$  è equivalente a risolvere il seguente problema di

programmazione lineare:

$$\begin{cases} \min v \\ v \geq \sum_{i=1}^m c_{ij} x_i \quad \forall j = 1, \dots, n \\ x \geq 0 \\ \sum_{i=1}^m x_i = 1 \end{cases} \quad := P_1$$

### Teorema

Il problema  $\max_{y \in Y} (\min_{x \in X} x^T C y)$  è equivalente a risolvere il seguente problema di programmazione lineare:

$$\begin{cases} \max w \\ w \geq \sum_{j=1}^n c_{ij} y_j & \forall i = 1, \dots, m \\ y \geq 0 \\ \sum_{j=1}^n y_j = 1 \end{cases} \quad := P_2$$

### Proposizione

$P_2$  è il duale di  $P_1$

### Risoluzione Esercizi

I Pure Strategies Nash Equilibria possono essere cercati fra i **minimi di ogni colonna** della matrice per  $Player_1$  e i **massimi di ogni riga** per  $Player_2$ .

**I punti in comune sono Pure Strategies Nash Equilibria.**

### Nota

**SE** il  $P_1$  è convesso  $\rightarrow$  Qualsiasi combinazione convessa fra due Pure Strategies Nash Equilibrium è una Mixed Strategies Nash Equilibria

### Definizione Combinazione Convessa con due punti

$$\alpha x_1 + (1 - \alpha)x_2 \quad \alpha \in [0, 1]$$



## GAME THEORY – Bimatrix Games

### Definizione

Un Bimatrix Game è un two-person non-cooperative game, dove:

- $X$  e  $Y$  sono set finiti:
  - $X = \{x \in \mathbb{R}^m: x \geq 0, \sum_{i=1}^m x_i = 1\}$
  - $Y = \{y \in \mathbb{R}^n: y \geq 0, \sum_{j=1}^n y_j = 1\}$
- $f_1 \neq -f_2$  (non zero-sum game)
  - $f_1(x, y) = x^T C_1 y$
  - $f_2(x, y) = x^T C_2 y$

### Teorema

Ogni Bimatrix Game ha almeno un Mixed Strategies Nash Equilibrium

### Teorema

Definendo  $B_1: Y \rightarrow X$  e  $B_2: X \rightarrow Y$ :

$$B_1(y) = \{ \text{Soluzioni ottime di } \min_{x \in X} x^T C_1 y \}$$
$$B_2(x) = \{ \text{Soluzioni ottime di } \min_{y \in Y} x^T C_2 y \}$$

→  $(x^*, y^*)$  è un Nash Equilibrium **SSE**  $x^* \in B_1(y)$  e  $y^* \in B_2(x)$

### Teorema – KKT per Bimatrix Games

$(x^*, y^*)$  è un Nash Equilibrium **SSE**  $\exists \mu_1, \mu_2 \in \mathbb{R}$ :

$$\left\{ \begin{array}{l} C_1 y^* + \mu_1 e_m \geq 0 \\ x^* \geq 0 \\ \sum_{i=1}^m x_i^* = 1 \\ x_i^* (C_1 y^* + \mu_1 e_m) \geq 0. \quad \forall i = 1 \dots m \\ C_2 x^* + \mu_2 e_n \geq 0 \\ y^* \geq 0 \\ \sum_{j=1}^n y_j^* = 1 \\ y_j^* (C_2 x^* + \mu_2 e_n) \geq 0. \quad \forall j = 1 \dots n \end{array} \right. \quad := KS$$

È Verificato

### Proposizione

$(x^*, y^*, \mu_1, \mu_2)$  è una soluzione per **KS SSE** è una soluzione ottima del problema di programmazione quadratica seguente:

$$\left\{ \begin{array}{l} \min \psi(x, y, \mu_1, \mu_2) = [x^T (C_1 y + \mu_1 e_m) + y^T (C_2 x + \mu_2 e_n)] \\ C_1 y + \mu_1 e_m \geq 0 \\ x \geq 0 \\ \sum_{i=1}^m x_i = 1 \\ C_2 x + \mu_2 e_n \geq 0 \\ y \geq 0 \\ \sum_{j=1}^n y_j = 1 \end{array} \right. \quad := QP$$

E  $\psi(x^*, y^*, \mu_1, \mu_2) = 0$

**Formato Matriciale di  $QP$**

$$\begin{cases} \min \frac{1}{2} (w^T, \mu^T) H \begin{pmatrix} w \\ \mu \end{pmatrix} \\ A_{in} \begin{pmatrix} w \\ \mu \end{pmatrix} \leq b_{in} \\ A_{eq} \begin{pmatrix} w \\ \mu \end{pmatrix} \leq b_{eq} \\ w \geq 0 \end{cases} := QP$$

Con: ( $O ==$  matrice di uni)

$$H = \begin{pmatrix} O_{m \times m} & C_1 + C_2 & e_m & O_{m \times 1} \\ C_1^T + C_2^T & O_{n \times n} & O_{n \times 1} & e_n \\ e_m^T & O_{1 \times n} & 0 & 0 \\ O_{1 \times m} & e_n^T & 0 & 0 \end{pmatrix}$$

$$A_{in} = \begin{pmatrix} -C_2^T & O_{n \times n} & O_{n \times 1} & -e_n \\ O_{m \times m} & -C_1 & -e_m & O_{m \times 1} \end{pmatrix} \quad b_{in} = \begin{pmatrix} O_{n \times 1} \\ O_{m \times 1} \end{pmatrix}$$

$$A_{eq} = \begin{pmatrix} 1 & \dots & 1 & 0 & \dots & 0 & 0 & 0 \\ 0 & \dots & 0 & 1 & \dots & 1 & 0 & 0 \end{pmatrix} \quad b_{eq} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$w^T = (x^T, y^T)$$

## GAME THEORY – Convex Games

$$P_1 \rightarrow \begin{cases} \min_x f_1(x, y) \\ g_i^1(x) \leq 0, \quad \forall i = 1 \dots p \end{cases}, \quad P_2 \rightarrow \begin{cases} \min_y f_2(x, y) \\ g_j^2(y) \leq 0, \quad \forall j = 1 \dots q \end{cases}$$

Con  $f_1, f_2, g^1$  e  $g^2$  continue e differenziabili

### Teorema

**SE** le regioni di ammissione

- $X = \{x \in \mathbb{R}^m: g_i^1(x) \leq 0, \quad \forall i = 1 \dots p\}$
- $Y = \{y \in \mathbb{R}^n: g_j^2(y) \leq 0, \quad \forall j = 1 \dots q\}$

Sono chiuse, limitate e convesse e le funzioni di costo:

- 1)  $f_1(\bullet, y)$  è quasi-convessa  $\forall y \in Y$
- 2)  $f_2(x, \bullet)$  è quasi-convessa  $\forall x \in X$

→ esiste almeno un Nash Equilibrium

### Teorema – Condizione KKT

**SE**  $(x^*, y^*)$  è un Nash Equilibrium e ACQ sono verificati sia in  $x^*$  che in  $y^*$  →  $\exists \lambda^1 \in \mathbb{R}^p$  e  $\exists \lambda^2 \in \mathbb{R}^q$ :

$$\left\{ \begin{array}{l} \nabla_x f_1(x^*, y^*) + \sum_{i=1}^p \lambda_i^1 \nabla g_i^1(x^*) = 0 \\ \lambda^1 \geq 0 \\ g^1(x^*) \leq 0 \\ \lambda_i^1 g_i^1(x^*) = 0 \quad \forall i = 1, \dots, p \\ \nabla_y f_2(x^*, y^*) + \sum_{j=1}^q \lambda_j^2 \nabla g_j^2(y^*) = 0 \\ \lambda^2 \geq 0 \\ g^2(y^*) \leq 0 \\ \lambda_j^2 g_j^2(y^*) = 0 \quad \forall j = 1, \dots, q \end{array} \right.$$

**SE**  $(x^*, y^*, \lambda^1, \lambda^2)$  risolve il KKT di sopra, e il game è convesso →  $(x^*, y^*)$  è un Nash Equilibrium

## MATLAB

**Funzione** *linprog* (*f*, *A*, *b*, *Aeq*, *beq*, *lb*, *ub*, *opzioni*)

Dove. Il sistema che risolve, in generale è fatto:

$$\begin{cases} \min_x (f^T x) \\ Ax \leq b \\ Aeq x = b. \\ lb \leq x \leq ub \end{cases}$$

**Funzione** *quadprog* (*H*, *f*, *A*, *b*, *Aeq*, *beq*, *lb*, *ub*, *x<sub>0</sub>*, *opzioni*)

Dove. Il sistema che risolve, in generale è fatto:

$$\begin{cases} \min_x \left( \frac{1}{2} x^T H x + f^T x \right) \\ Ax \leq b \\ Aeq x = beq \\ lb \leq x \leq ub \end{cases}$$

**Funzione**

*[x, fval, exitflag, output, lambda] = fmincon (fun, x<sub>0</sub>, A, b, Aeq, beq, lb, ub, nonlcon)*

Dove. Il sistema che risolve, in generale è fatto:

$$\begin{cases} \min_x f(x) \\ Ax \leq b \\ Aeq x = beq \\ lb \leq x \leq ub \\ c(x) \leq 0 \\ ceq(x) = 0 \end{cases}$$

*fun = @(x) ...*

*nonlcon = @(x) const(x)*

*function [c, ceq] = const(x)*

*c = [...];*

*ceq = [...];*

*end*

**Funzione** *fminunc* uguale ma senza vincoli

## RISOLUZIONE ESERCIZI

### ESERCIZIO 1: Mono-Objective

- 1) **Provare se il problema ammette un ottimo globale**
  - a. Controllare se  $f(x)$  è convessa tramite gli auto-vettori dell'Hessiana
  - b. Controllare se  $f(x)$  è continua nel set  $X$  di ammissione
- 2) **Applicare il metodo indicato tramite lo script MatLab**
- 3) **Il punto ottenuto è un minimo globale del problema?**
  - a. Se  $f(x)$  è strongly convex allora il minimo globale è unico
  - b. Per farlo bisogna vedere se la soluzione trovata è anche soluzione del  $KKT$  associato al problema. Usando il teorema che dice: SE il problema  $P$  è convesso e  $(\lambda^*, \mu^*, x^*)$  è la soluzione del  $KKT \rightarrow x^*$  è un ottimo globale

### ESERCIZIO 2: SVM

- 1) **Scrivere il modello richiesto, copiandolo da sopra.**
- 2) **Risolvere usando MatLab, con i parametri descritti dalla traccia**
- 3) **Trovare i punti miss-classified**
  - a. Bisogna considerare la “complementary slackness condition”, in particolare se il punto è miss-classificato allora l'errore  $\xi_i^* > 0$ , per cui da  $(C - \lambda_i^*)\xi_i^* = 0$  deriviamo  $C = \lambda_i^*$ . Cercare i punti con questo  $\lambda_i^*$ . Ma non basta, potrebbero esserci punti classificati correttamente anche con  $C = \lambda_i^*$ . Per notarlo basta calcolare il valore dell'Iperpiano con il punto indicato, e vedere se soddisfa:
    - i.  $w^T x_i + b > 0 \quad \forall x_i \in A$
    - ii.  $w^T x_i + b < 0 \quad \forall x_i \in B$
- 4) **Classifica il nuovo punto**
  - a. Bisogna vedere se:
    - i.  $w^T x_i + b > 0 \quad \forall x_i \in A$
    - ii.  $w^T x_i + b < 0 \quad \forall x_i \in B$

### ESERCIZIO 2: Regressione

- 1) **Scrivere il modello richiesto, copiandolo da sopra.**
- 2) **Risolvere usando MatLab, con i parametri descritti dalla traccia**
- 3) **Trovare i Support Vector:**
  - a. Usare MatLab, i SV sono dati dalla seconda e dalla terza colonna
- 4) **Trovare i punti che cadono fuori dal  $\varepsilon$  - tube usando la soluzione del duale**
  - a. Guardando le condizioni del primale:
    - i.  $y_i - f(x_i) - \varepsilon - \xi_i^+ \leq 0$
    - ii.  $y_i - f(x_i) + \varepsilon + \xi_i^+ \leq 0$Se un punto è fuori dal  $\varepsilon$  - tube, allora l'errore è  $\xi_i^+, \xi_i^- > 0$   
Bisogna cercare i punti a cui corrisponde un errore positivo, cerchiamo prima nella soluzione duale i punti  $(\lambda^+, \lambda^-)$ , e cerchiamo i punti che hanno  $C = \lambda_i^*$ , per lo stesso principio del problema  $SVM$ .

### ESERCIZIO 2: Clustering

- 1) **Scrivere il modello richiesto, copiandolo da sopra.**
- 2) **Risolvere usando MatLab, con i parametri descritti dalla traccia**

### ESERCIZIO 3: Multi-Objective

#### 1) Prova l'esistenza del Minimo di Pareto, trovare i $WMin(P)$ e i $Min(P)$

- a. Per farlo risolvere il  $P_\alpha$  dello scalarized problem, attraverso il  $KKT$ , provando che il problema  $P_\alpha$  è convesso e che le  $ACQ$  sono soddisfatti:
  - i. Per  $\alpha_1 = 0$
  - ii. Per  $\alpha_1 = 1$
  - iii. Per  $0 < \alpha_1 < 1$ 
    1. Distinguere i casi per  $\lambda = 0$  e  $\lambda > 0$
- b. **SE** il problema  $P$  è lineare allora tutti i risultati trovati sono  $WMin(P)$  o  $Min(P)$  secondo il teorema di sopra descritto
- c. **SE** una delle  $f_i$  è Strongly Convex allora ha un unico minimo che è un  $Min(P)$

### ESERCIZIO 4: Mono-Matrix

#### 1) Trovare le strategie dominate per eliminarle:

- a. Player 2: Eliminiamo le **colonne** che hanno tutti i valori  $\leq$  agli elementi corrispondenti delle altre colonne (Mi tengo la colonna maggiore)
- b. Player 1: Eliminiamo le **righe** che hanno tutti i valori  $\geq$  agli elementi corrispondenti delle altre righe (Mi tengo la riga minore)

#### 2) Trovare le Pure Strategies Nash Equilibria

- a. Cercare gli elementi che sono contemporaneamente **massimi per la propria riga e minimi per la propria colonna**.
- b. Ricordare di mantenere gli indici della matrice originale

#### 3) Trovare un Mixed Strategies Nash Equilibria

- a. Risolvere il sistema primale dato dalla definizione sopra, con MatLab
- b. **SE** il risultato del sistema è un Pure Strategies Nash Equilibria, allora controllare se il problema è lineare, per cui ogni combinazione convessa fra due punti di Pure Strategies Nash Equilibria è un Mixed Strategies Nash Equilibria.

### ESERCIZIO 4: Bi-Matrix

#### 1) Fa tutto MatLab 😂